

Projet de final

Dates de disponibilité : Du 06 décembre 2024 à 06h00 au 18 décembre 2024 à 23h59.

Introduction

Dans ce projet, vous êtes invités à appliquer certaines techniques d'apprentissage automatique (*Machine Learning*) pour la classification et l'estimation/prédiction sur des jeux de données et à discuter les résultats obtenus. Le projet est composé de deux parties. Dans la première partie, vous serez guidés dans votre démarche par des questions auxquelles vous devez répondre de façon convaincante et claire. Toutefois, dans votre milieu de travail, votre gestionnaire ne va pas vous guider dans votre exploration des données. Il vous posera la problématique et vous demandera d'explorer les données disponibles pour résoudre le problème. Ainsi, dans la deuxième partie du projet, nous vous demanderons d'explorer un jeu de données pour résoudre un problème particulier. Vous aurez la liberté de faire tout ce que vous jugerez nécessaire. Comme outil d'exploration de données, il est recommandé d'utiliser le logiciel SPSS-Modeler. Toutefois, l'utilisation de tout outil de votre choix qui répond aux attentes du travail sera acceptée.

Consignes

Vous devez fournir un rapport qui inclut :

1. Les réponses aux questions.
2. Vos analyses, remarques et justifications.
3. Des captures d'écran montrant clairement les modèles simulés.

Les documents à déposer dans la boîte de dépôt sont :

1. La version pdf de votre rapport (**obligatoire**).
2. Les flux SPSS modeler utilisés (optionnel).

Important : pour chaque flux SPSS-Modeler simulé, n'oubliez pas d'indiquer les configurations et les paramètres importants considérés.

Contexte

La pandémie de Covid-19 a bouleversé les modèles de travail traditionnels, accélérant l'adoption du télétravail et des solutions numériques dans de nombreuses entreprises. Face aux restrictions sanitaires, les employeurs ont dû repenser l'organisation du travail pour assurer la continuité des activités, favorisant une flexibilité accrue et des horaires de travail plus souples. L'ensemble de données « COVID-impact » contient 9000 points de données, offrant une vue d'ensemble de la manière dont la pandémie COVID-19 a affecté les modes de travail des professionnels dans divers secteurs. Cet ensemble de données permet de prédire les tendances futures, d'analyser les changements de comportement des professionnels et de formuler des politiques efficaces pour gérer des crises similaires.

Dans cette partie du projet, nous nous intéressons à la classification en utilisant l'algorithme des k plus proches voisins (K-Nearest Neighbour – KNN), les arbres de décision et les réseaux de neurones. Nous utiliserons le jeu de données « COVID-impact » dont chaque ligne représente un individu et qui comprend 16 colonnes détaillant les différents aspects de l'impact de la pandémie sur leur vie professionnelle. Notre **objectif** est de créer un modèle de classification permettant de prédire **si un employé est susceptible de travailler à domicile**.

Travail demandé

1. Présentez une très brève analyse descriptive du jeu de données « COVID-impact ». Quelles conclusions tirez-vous de cette l'analyse descriptive ? (2 points)
2. Créez un modèle KNN en utilisant le jeu de données « COVID-impact ». Utilisez comme entrées pour le modèle KNN les variables que vous jugez utiles. Partagez le jeu en « données d'apprentissage » (75%) et « données de test » (25%).
 - a. Fournissez une capture d'écran montrant le modèle créé et donnez les configurations et les paramètres importants. (1 point)
 - b. Déterminez la valeur optimale de k. (1 point)
 - c. Donnez la matrice de confusion du modèle qui utilise la valeur optimale de k. (1 point)
 - d. Déterminez le taux de succès (accuracy) du modèle optimal ainsi que sa sensibilité (rappel) et sa précision. (1 point)
 - e. Identifiez le ou les prédicteur(s) important(s) du modèle KNN optimal. (1 point)
3. Créez un modèle CART et un modèle C5.0 en utilisant le jeu « COVID-impact ». Partagez le jeu en « données d'apprentissage » (75%) et « données de test » (25%).
 - a. Fournissez une capture d'écran montrant chaque modèle créé et donnez les configurations et les paramètres importants. (1 point)
 - b. Pour chaque modèle, déterminez le premier attribut discriminant. (1 point)
 - c. Pour chaque modèle, déterminez le taux de succès (accuracy). (1 point)
 - d. Trouvez un moyen pour améliorer les performances obtenues. (1 point)
 - e. Pour chaque modèle amélioré, déterminez la sensibilité et la précision. (1 point)

4. Créez un modèle de réseau neuronal en utilisant le jeu de données « COVID-impact ». Partagez le jeu en « données d'apprentissage » (75%) et « données de test » (25%). Utiliser les paramètres par défaut fournis par SPSS Modeler.
 - a. Fournissez une capture d'écran montrant le modèle créé et donnez les configurations et les paramètres importants. (1 point)
 - b. Combien de couches cachées et d'unités sont incluses dans le modèle ? (1 point)
 - c. Déterminez le taux de succès du modèle ainsi que sa sensibilité et sa précision. (1 point)
 - d. Utilisez le « boosting » pour améliorer les performances du modèle. (1 point)
5. Utilisez les modèles KNN, les arbres de décision et les réseaux de neurones pour classer les enregistrements du jeu de données « COVID-impact-null ». Que peut-on conclure ? (2 points)

Description du jeu de données

Le jeu de données contient 9000 enregistrements et 16 variables définies par :

ID	Identifiant de l'individu.
<i>Increased_Work_Hours</i>	Indique si les heures de travail de la personne ont augmenté en raison de la pandémie (1 pour une augmentation, 0 pour un maintien ou une diminution).
<i>Work_From_Home</i>	Indique si la personne a commencé à travailler à domicile en raison de la pandémie (1 pour oui, 0 pour non).
<i>Hours_Worked_Per_Day</i>	Le nombre moyen d'heures travaillées par jour.
<i>Meetings_Per_Day</i>	Le nombre moyen de réunions virtuelles auxquelles l'individu participe par jour.
<i>Productivity_Change</i>	Indique si la productivité de l'individu a changé en raison de la pandémie (1 pour une augmentation ou une diminution de la productivité, 0 pour aucun changement).
<i>Stress_Level</i>	Niveau de stress auto-déclaré (Low, Medium, High).
<i>Health_Issue</i>	Indique si la personne a développé de nouveaux problèmes de santé (mentale ou physique) au cours de la pandémie (1 pour oui, 0 pour non).
<i>Job_Security</i>	Perception de la sécurité de l'emploi pendant la pandémie (1 indiquant un sentiment de moindre sécurité).
<i>Childcare_Responsibilities</i>	Les responsabilités en matière de garde d'enfants ont-elles augmenté à la suite de la pandémie (1 pour une augmentation des responsabilités, 0 pour aucun changement ou une diminution) ?
<i>Commuting_Changes</i>	Reflète les changements dans les habitudes de déplacement dus à la pandémie, tels que la réduction ou l'absence de déplacement (1 pour les changements, 0 pour l'absence de changement).
<i>Technology_Adaptation</i>	L'individu s'est-il adapté aux nouvelles technologies pour le travail à distance (1 pour oui, 0 pour non) ?
<i>Salary_Changes</i>	Indique si l'individu a connu des changements de salaire pendant la pandémie (1 pour un changement (augmentation ou diminution), 0 pour un salaire inchangé).
<i>Team_Collaboration_Challenges</i>	Indique s'il y a eu des problèmes de collaboration entre les équipes pendant la pandémie (1 pour oui, 0 pour non).
<i>Sector</i>	Le secteur dans lequel l'individu est employé (Healthcare, IT, Retail, etc.)
<i>Affected_by_Covid</i>	Indique si la vie professionnelle de l'individu a été affectée par le COVID.

Fichiers pour les jeux de données : COVID-impact.xlsx et COVID-impact_null.xlsx.

Contexte

Dans cette partie du projet, nous considérons le jeu de données « Clients ». Il s'agit d'un ensemble de données avec des caractéristiques de 10 000 clients de votre entreprise qui a un système de carte de fidélité et qui propose des produits et des services en ligne à sa clientèle. Votre entreprise compte lancer une campagne de publicité ciblée. Elle envisage d'utiliser deux stratégies de publicité. La première stratégie est destinée aux clients ayant une « Valeur moyenne du panier d'achat » inférieure ou égale à 150 \$ et la deuxième stratégie cible les clients avec une « Valeur moyenne du panier d'achat » supérieure à 150 \$. Votre gestionnaire vous demande de l'aider à identifier les clients ayant tendance à dépenser plus par transaction et à orienter les stratégies marketing en fonction de leur potentiel de dépense. Ainsi, pour bien cibler les publicités, votre gestionnaire veut classer les clients en deux catégories. Il vous fournit le jeu de données des 10 000 clients et un autre jeu avec des clients non classés. Il vous demande de trouver le meilleur moyen pour arriver à cette fin.

Travail demandé

Votre travail consiste à essayer les algorithmes KNN, les arbres de décision, les forêts aléatoires et les réseaux de neurones pour trouver la meilleure approche de classification. Vous devez aussi classer les clients du deuxième jeu (Clients_null) selon toutes les approches (KNN, arbres de décision, forêt aléatoire et réseaux de neurones), puis fournir une conclusion à votre gestionnaire. N'oubliez pas que l'exploration de données est un processus à plusieurs étapes.

Barème :

1. Compréhension et préparation des données. (2 points)
2. Modélisation (KNN, arbres de décision, forêts aléatoires et réseaux de neurones). (4 points)
3. Évaluation des performances. (3 points)
4. Déploiement (utilisation des modèles créés et bref rapport). (3 points)

Description du jeu de données

1. Le jeu de données contient 10 000 enregistrements et 13 variables définies par :

<i>Client_ID</i>	Identifiant du client.
<i>Age</i>	Âge du client.
<i>Genre</i>	Genre du client (Femme/Homme).
<i>Revenu</i>	Revenu annuel du client en milliers de dollars.
<i>Durée_adhésion</i>	Ancienneté en mois.
<i>Dernier_achat</i>	Temps écoulé depuis le dernier achat (en jours).
<i>Moy_valeur_panier</i>	Valeur moyenne du panier d'achat.
<i>Catégorie_favorite</i>	Catégorie préférée de produit ("Beauté", "Électronique", "Maison", "Mode", "Sport").
<i>Abonné_newsletter</i>	Abonnement à la newsletter (Oui/Non).
<i>Segment</i>	Segment du client ("VIP", "Fidèle", "Occasionnel", "Prospect").
<i>Visites_en_ligne_dernier_mois</i>	Nombre de visites en ligne sur le site le mois dernier.
<i>Points_de_fidélité</i>	Points de fidélité accumulés.
<i>Social_media_engagement</i>	Niveau d'engagement sur les réseaux sociaux (de 0 à 5).

Fichiers pour les jeux de données : Clients.xlsx et Clients_null.xlsx.