

Projet de final

Du 06 décembre 2024 au 18 décembre 2024

Nom et Prénom de l'étudiant

Fotsi Elvis Romarick

111 249 147




TABLE DE MATIÈRES

Table de Matières.....	1
Partie I : Contexte.....	3
1. Analyse descriptive du jeu de données.....	4
2. Création du modèle KNN	9
a. Fournissez une capture d'écran montrant le modèle créé et donnez les configurations et les paramètres importants.	9
b. Déterminez la valeur optimale de k	12
c. Donnez la matrice de confusion du modèle qui utilise la valeur optimale de k ...	12
d. Déterminez le taux de succès (accuracy) du modèle optimal ainsi que sa sensibilité (rappel) et sa précision	12
e. Identifiez le ou les prédicteur(s) important(s) du modèle KNN optimal	13
3. Création des modèles CART et C5.0.....	14
a. Fournissez une capture d'écran montrant chaque modèle créé et donnez les configurations et les paramètres importants	14
b. Pour chaque modèle, déterminez le premier attribut discriminant.....	15
c. Pour chaque modèle, déterminez le taux de succès (accuracy).....	16
d. Trouvez un moyen pour améliorer les performances obtenues.....	17
e. Pour chaque modèle amélioré, déterminez la sensibilité et la précision.....	18
4. Création d'un modèle de réseau neuronal	19
a. Fournissez une capture d'écran montrant le modèle créé et donnez les configurations et les paramètres importants	19
b. Combien de couches cachées et d'unités sont incluses dans le modèle ?.....	20
c. Déterminez le taux de succès du modèle ainsi que sa sensibilité et sa précision	21
d. Utilisez le « boosting » pour améliorer les performances du modèle.....	22
5. Utilisation des modèles KNN, les arbres de décision et les réseaux de neurones pour classer les enregistrements du jeu de données « COVID-impact-null ». Que peut-on conclure ?.....	23
Partie II : Contexte.....	24
1. Analyse descriptive du jeu de données Clients.....	25
2. Modélisation	30
a. Modélisation par KNN.....	30
b. Modélisation par arbres de décision	31

c.	Modélisation par forêts aléatoires.....	35
d.	Modélisation par réseaux de neurones.....	38
3.	Evaluation des performances.....	39
4.	Déploiement (utilisation des modèles créés et bref rapport)	39

Partie I : Contexte

La pandémie de Covid-19 a bouleversé les modèles de travail traditionnels, accélérant l'adoption du télétravail et des solutions numériques dans de nombreuses entreprises. Face aux restrictions sanitaires, les employeurs ont dû repenser l'organisation du travail pour assurer la continuité des activités, favorisant une flexibilité accrue et des horaires de travail plus souples. L'ensemble de données « COVID-impact » contient 9000 points de données, offrant une vue d'ensemble de la manière dont la pandémie COVID-19 a affecté les modes de travail des professionnels dans divers secteurs. Cet ensemble de données permet de prédire les tendances futures, d'analyser les changements de comportement des professionnels et de formuler des politiques efficaces pour gérer des crises similaires.

Dans cette partie du projet, nous nous intéressons à la classification en utilisant l'algorithme des k plus proches voisins (K-Nearest Neighbour – KNN), les arbres de décision et les réseaux de neurones. Nous utiliserons le jeu de données «COVID-impact» dont chaque ligne représente un individu et qui comprend 16 colonnes détaillant les différents aspects de l'impact de la pandémie sur leur vie professionnelle. Notre objectif est de **créer un modèle de classification permettant de prédire si un employé est susceptible de travailler à domicile.**

1. Analyse descriptive du jeu de données

Le jeu de données contient 9000 enregistrements et 16 variables présentées dans le tableau 1 ci-après, assorties de la nature de chacune des variables. Concernant la nature de ces variables, 13 sont catégorielles et 03 numériques.

Le jeu de données ne contient pas de valeurs manquantes.

Tableau 1 : Présentation des différentes variables du jeu de données

Nom de la variable	Description de la variable	Nature de la variable
ID	Identifiant de l'individu	Numérique
Increased_Work_Hours	Indique si les heures de travail de la personne ont augmenté en raison de la pandémie (1 pour une augmentation, 0 pour un maintien ou une diminution).	Catégorielle
Work_From_Home	Indique si la personne a commencé à travailler à domicile en raison de la pandémie (1 pour oui, 0 pour non).	Catégorielle
Hours_Worked_Per_Day	Le nombre moyen d'heures travaillées par jour.	Numérique
Meetings_Per_Day	Le nombre moyen de réunions virtuelles auxquelles l'individu participe par jour.	Numérique
Productivity_Change	Indique si la productivité de l'individu a changé en raison de la pandémie (1 pour une augmentation ou une diminution de la productivité, 0 pour aucun changement).	Catégorielle
Stress_Level	Niveau de stress auto-déclaré (Low, Medium, High).	Catégorielle
Health_Issue	Indique si la personne a développé de nouveaux problèmes de santé (mentale ou physique) au cours de la pandémie (1 pour oui, 0 pour non).	Catégorielle
Job_Security	Perception de la sécurité de l'emploi pendant la pandémie (1 indiquant un sentiment de moindre sécurité).	Catégorielle
Childcare_Responsibilities	Les responsabilités en matière de garde d'enfants ont-elles augmenté à la suite de la pandémie (1 pour une augmentation des responsabilités, 0 pour aucun changement ou une diminution) ?	Catégorielle
Commuting_Changes	Reflète les changements dans les habitudes de déplacement dus à la pandémie, tels que la réduction ou l'absence de déplacement (1 pour les changements, 0 pour l'absence de changement).	Catégorielle
Technology_Adaptation	L'individu -il adapté aux nouvelles technologies pour le travail à distance (1 pour s'est oui, 0 pour non) ?	Catégorielle
Salary_Changes	Indique si l'individu a connu des changements de salaire pendant la pandémie (1 pour un changement (augmentation ou diminution), 0 pour un salaire inchangé).	Catégorielle
Team_Collaboration_Challenges	Indique s'il y a eu des problèmes de collaboration entre les équipes pendant la pandémie (1 pour oui, 0 pour non).	Catégorielle
Sector	Le secteur dans lequel l'individu est employé (Healthcare, IT, Retail, etc.)	Catégorielle
Affected_by_Covid	Indique si la vie professionnelle de l'individu a été affectée par le COVID.	Catégorielle


Les statistiques descriptives sur les variables numériques présentées dans le tableau 2 montrent que le nombre d'heures de travail moyen par jour est de 8 avec un écart type de 1,98. L'employé qui travaille le moins compte environ 30 minutes de travail par jour alors que d'autres travaillent jusqu'à 16,98 heures par jour. Le nombre moyen de réunions par jour au lieu de travail est de 3,99 avec un écart-type de 1,51. Il peut arriver d'avoir 9 réunions dans une journée de travail

Tableau 2 : Statistiques descriptives sur les variables numériques

	Hours_Worked_Per_Day	Meetings_Per_Day
Valid	9000	9000
Missing	0	0
Mean	8.008	3.996
Std. Deviation	1.986	1.513
Minimum	0.290	0.010
Maximum	16.960	9.600


Dans le cadre de l'analyse des variables catégorielles, la figure 1 ci-dessous montre que 80,39% des employés ont commencé à travailler à domicile en raison de la pandémie.

Figure 1 : Répartition de la population suivant la variable *Work_From_Home* (en %)




Aussi, 49,82% des employés ont déclaré que la pandémie leur a créé un niveau de stress moyen.

Figure 2 : Répartition de la population suivant la variable *Stress_Level* (en %)



Concernant la répartition des employés par secteur d'activité, le secteur des technologies de l'information (IT) compte relativement le plus grand pourcentage (25,54%). Toutefois, on n'observe pas de fortes disparités d'un secteur à un autre.

Figure 3 : Répartition de la population suivant la variable *Sector* (en %)



Par ailleurs, 40,51% des employés estiment être moins en sécurité pendant la pandémie et 50,17% déclarent que leur productivité a changé (augmenté ou diminué) en raison de la pandémie. Cependant, des informations collectées, 30,36% des employés ont développé des problèmes de santé (mentale ou physique) au cours de la pandémie. Les responsabilités en matière de garde d'enfants ont augmenté à la suite de la pandémie pour 39,79% des employés. 50,21% des employés ont eu des changements dans les habitudes de déplacement dus à la pandémie, tels que la réduction ou l'absence de déplacement et 60,65% se sont adaptés aux nouvelles technologies pour le travail à distance. Un peu plus de 19% des employés ont connu un changement de salaires. Enfin, plus de 70% des employés ont eu des problèmes de collaboration entre les équipes


pendant la pandémie. Pour la totalité des employés, la vie professionnelle a été affectée par le Covid.

Tableau 3 : Statistiques descriptives sur les variables qualitatives

Variables	% Non (0)	% Oui (1)	Total
Job security	59,49	40,51	100,00
Productivity_change	49,83	50,17	100,00
Health Issue	69,64	30,36	100,00
Childcare responsibility	60,22	39,79	100,00
Commuting Changes	49,78	50,21	100,00
Technology adaptation	39,44	60,65	100,00
Salary changes	80,61	19,39	100,00
Team collaboration challenges	28,83	70,17	100,00


A priori, nous avons analysé la relation entre la variable *Work_From_Home* et certaines variables. Par exemple, le secteur d'activité ne semble pas influencer le lieu de travail. En effet, 80% environ du personnel de chaque secteur travaille à domicile.

Figure 3: Influence de la variable « Sector » sur la variable «*Work_From_Home*»



Le nombre d'heures de travail ne semble pas également avoir une influence importante sur la décision pour un employé de travailler à domicile. En effet, les boîtes à moustaches présentées dans la figure 4 ont des niveaux moyennes sensiblement égales.

Figure 4: Influence de la variable « Sector » sur la variable «*Work_From_Home*»



2. Création du modèle KNN

Avant de répondre aux questions posées, il est important de préciser que suivant les informations dans le tableau descriptif des variables, la variable *Stress_Level* est codifiée en ordinale.

Encadré 1 : Codification des variables avec choix de la variable cible.

Types (de rangs) Format Annotations					
Champ	Mesure	Valeurs	Manqu...	Vérifier /	Rôle
ID	Sans type			Aucun	ID en...
Increased_Work...	Nominal	"0.000000","1.000000"		Aucun	Entrée
Work_From_Ho...	Indicateur	"1.000000"/"0.000000"		Aucun	Cible
Hours_Worked_...	Continu	[0.290000000000000004,16.96]		Aucun	Entrée
Meetings_Per_D...	Continu	[0.01,9.6]		Aucun	Entrée
Productivity_Cha...	Nominal	"0.000000","1.000000"		Aucun	Entrée
Stress_Level	Ordinal	High,Low,Medium		Aucun	Entrée
Health_Issue	Nominal	"0.000000","1.000000"		Aucun	Entrée
Job_Security	Nominal	"0.000000","1.000000"		Aucun	Entrée
Childcare_Resp...	Nominal	"0.000000","1.000000"		Aucun	Entrée
Commuting_Ch...	Nominal	"0.000000","1.000000"		Aucun	Entrée
Technology_Ada...	Nominal	"0.000000","1.000000"		Aucun	Entrée
Salary_Changes	Nominal	"0.000000","1.000000"		Aucun	Entrée
Team_Collabor...	Nominal	"0.000000","1.000000"		Aucun	Entrée
Sector	Nominal	Education,Healthcare,IT,Retail		Aucun	Entrée
Affected_by_Covid	Indicateur	"1.000000"/"1.000000"		Aucun	Aucun

a. Fournissez une capture d'écran montrant le modèle créé et donnez les configurations et les paramètres importants.

La base est partitionnée en échantillon d'entraînement (74%) et test (25%).

Encadré 2 : Partitionnement de la base de données

L'objectif est de prédire un champs cible.

Encadré 3 : Objectifs de la modélisation

Objectifs Champs Paramètres Annotations

La procédure kNN va identifier les observations d'apprentissage les plus semblables (les voisins les plus proches) aux observations qui vous intéressent. Un champ cible peut être prévu en fonction des valeurs voisines.

Quel type d'analyse souhaitez-vous effectuer ?

- ☒ Prédire un champ cible
- ☐ Identifier uniquement les voisins les plus proches

Quel est votre objectif ?

- ☐ Equilibrer vitesse et précision
Sélectionne automatiquement le nombre optimal de voisins dans un petit intervalle.
- ☐ Vitesse
Recherche un nombre fixe de voisins.
- ☐ Précision
Sélectionne automatiquement le nombre optimal de voisins dans un grand intervalle et utilise l'importance des prédécesseurs lors du calcul des distances.

☒ Analyse personnalisée
Sélectionnez cette option pour affiner l'algorithme dans l'onglet Paramètres.

OK Exécuter Annuler Appliquer Réinitialiser

La modalité 0 de la variable work_from_Home est équilibrée avec un facteur de 4.5. Nous avons dans un premier temps essayé un facteur de 3 sans observer de changement la façon de prédire les modalités de la variable cible.

Encadré 5: Equilibrer les données

Paramètres Aperçu Annotations

Directives d'équilibrage :

Facteur	Condition
3.0	Work_From_Home=0

☒ Données d'apprentissage d'équilibrage uniquement

Les données ont été normalisées.

Encadré 4: Normalisation des données

Paramètres Objectifs Champs Annotations

Modèle

Nom du modèle : ☐ Automatique ☐ Personnalisé

☒ Utiliser les données partitionnées

☒ Créer un modèle pour chaque division

Partition :

Divisions :


☒ Normaliser les entrées de plage

☐ Utiliser des libellés d'observation

☐ Identifier l'enregistrement focal


Le nombre de voisins k a été choisi par validation croisée entre 1 et 20.

Encadré 5 : Spécification de la sélection du nombre de voisin entre 1 et 20



Le nombre de niveaux retenu est 5 dans la validation croisée.


Encadré 6 : Nombre de niveaux de la validation croisée défini à 5



b. Déterminez la valeur optimale de k

La valeur optimale de K est 20. C'est la valeur qui minimise l'erreur.

Encadré 7 : Choix du k optimal



c. Donnez la matrice de confusion du modèle qui utilise la valeur optimale de k

Le modèle a été estimé avec k=20. La matrice de confusion construite sur l'échantillon test et obtenue à la suite de l'estimation du modèle avec k=20 est ci-dessous.

Encadré 8 : Matrice de confusion

'Partition' = 2_Test	0.000000	1.000000
0.000000	0	442
1.000000	1	1 810

d. Déterminez le taux de succès (accuracy) du modèle optimal ainsi que sa sensibilité (rappel) et sa précision

$$\text{Taux de succès (accuracy)} : TS = \frac{VP+VN}{n} = 1 - TE$$

$$TS = (1810+0)/2250=1810/2253 \quad TS = 80,38\%$$

Sensibilité ou rappel ou encore le taux de vrais positifs (sensitivity or recall) :

$$Se = TVP = \text{rappel} = \frac{VP}{VP + FN}$$

$$Se = 1810 / (1810+1) \quad \text{Se} = 99,94\%$$

La précision (precision) :

$$\text{précision} = \frac{VP}{VP + FP}$$

$$\text{Précision} = 1810/(1810+442) \quad \text{Précision} = 80,37\%$$

e. Identifiez le ou les prédicteur(s) important(s) du modèle KNN optimal

Les prédicteurs importants sont *Hours_worked_per_day*, *Meeting_per_day* et *Increased_work_hours*. Ils apparaissent sur l'encadré 7 montrant le choix du k optimal

3. Création des modèles CART et C5.0

a. Fournissez une capture d'écran montrant chaque modèle créé et donnez les configurations et les paramètres importants

L'arbre sera élagué pour éviter le surajustement.

Encadré 9: bases Option de génération CART

Work_From_Home

Objectif : Modèle standard

Champs Options de génération Options de modèle Annotations

Sélectionner un élément :

Objectif

Bases

Règles d'arrêt

Coûts et A priori

Ensembles

Avancé

Profondeur maximale d'arbre

☒ Par défaut (5)

☐ Personnalisé

Valeur: 5

Elagage

☒ Elagage de l'arbre pour éviter le surajustement

☐ Définir la différence maximale de risque (dans les erreurs standard)

Valeur: 1

Nombre maximal de substitutions: 5

Encadré 10: Objectifs Option de génération CART

Champs Options de génération Options de modèle Annotations

Sélectionner un élément :

Objectif

Bases

Règles d'arrêt

Coûts et A priori

Ensembles

Avancé

Que voulez-vous faire ?

☒ Créer un modèle

☐ Poursuivre l'apprentissage du modèle existant

Quel est votre objectif principal ?

☒ Créer un arbre unique

Arbre unique

Mode: ☒ Générer un modèle ☐ Lancer une session interactive

☐ Utiliser les directives d'arbre

Directives...

☐ Améliorer la précision du modèle (boosting)


☐ Améliorer la stabilité du modèle (bagging)

☐ Créer un modèle pour les très grands jeux de données (requiert le serveur)


Description

Crée un modèle standard unique pour expliquer les relations entre les champs. Les modèles standard sont plus faciles à interpréter et peuvent être plus rapidement évalués que les jeux de données volumineux, améliorés ou agrégés.

Encadré 11: Modèle C5.0



Encadré 12: Aperçu de l'implémentation sur spss-modeler




b. Pour chaque modèle, déterminez le premier attribut discriminant

C5.0

L'arbre n'a pas de profondeur malgré le fait que les données soient équilibrées peu importe le facteur d'équilibre utilisé.

Modèle CART

La variable la plus discriminante est *Meetings_per_Day*.



c. Pour chaque modèle, déterminez le taux de succès (accuracy).

Malgré l'équilibrage des données, les modèles ne prédisent que les valeurs de 1.

Taux de succès (accuracy) : $TS = \frac{VP + VN}{n} = 1 - TE$

CART : Matrix de confusion

'Partition' = 2_Test	1.000000
0.000000	442
1.000000	1 811

$TS = 1811/2253$ **TS = 80,38%**

C5.0 Matrix de confusion

'Partition' = 2_Test	1.000000
0.000000	442
1.000000	1 811

$TS = 1811/2253$ **TS = 80,38%**

d. Trouvez un moyen pour améliorer les performances obtenues.

CART : Boosting utilisé

CART

Objectif : Précision du modèle (boosting)

Champs Options de génération Options de modèle Annotations

Sélectionner un élément :

Objectif

Bases

Règles d'arrêt

Coûts et A priori

Ensembles

Avancé

Que voulez-vous faire ?

☒ Créer un modèle ☐ Poursuivre l'apprentissage du modèle existant

Quel est votre objectif principal ?

☐ Créer un arbre unique

Arbre unique

Mode: ☒ Générer un modèle ☐ Lancer une session interactive

☐ Utiliser les directives d'arbre

☒ Améliorer la précision du modèle (boosting)

☐ Améliorer la stabilité du modèle (bagging)

☐ Créer un modèle pour les très grands jeux de données (requiert le serveur)

Description

Crée un ensemble en utilisant le boosting, qui génère une séquence de modèles pour obtenir des prévisions plus précises. La création et l'évaluation des ensembles peut prendre davantage de temps qu'un modèle standard.

C5.0 : Validation croisée

Work_From_Home

Champs Modèle Coûts Analyse Annotations

Nom du modèle : ☒ Automatique ☐ Personnalisé

☒ Utiliser les données partitionnées

☒ Créer un modèle pour chaque division

Type de sortie : ☒ Arbre décision ☐ Ensemble de règles

☐ Grouper les valeurs symboliques

☒ Utiliser l'amélioration

☒ Effectuer la validation croisée

Mode : ☒ Simple ☐ Expert

Préférence : ☒ Précision ☐ Généralité

Bruit théorique (%) :

Nombre d'essais :

Nombre de validations croisées :

e. Pour chaque modèle amélioré, déterminez la sensibilité et la précision

Les matrices de confusion obtenues sont identiques aux précédentes montrant qu'il n'y a d'amélioration réelles.

C5.0 : Matrix de confusion

'Partition' = 2_Test	1.000000
0.000000	442
1.000000	1 811

Sensibilité ou rappel ou encore le taux de vrais positifs (sensitivity or recall) :

$$Se = TVP = \text{rappel} = \frac{VP}{VP + FN}$$

$$Se = 1811 / (1811+0) \quad \text{Se} = 100\%$$

La précision (precision) :

$$\text{précision} = \frac{VP}{VP + FP}$$

$$\text{Précision} = 1811/(1811+442) \quad \text{Précision} = 80,38\%$$

Précision =

CART: Matrix de confusion



'Partition' = 2_Test	1.000000
0.000000	442
1.000000	1 811

$$\text{Se} = 100\%$$

$$\text{Précision} = 80,38\%$$

4. Création d'un modèle de réseau neuronal

a. Fournissez une capture d'écran montrant le modèle créé et donnez les configurations et les paramètres importants



Work_From_Home

Objectif : Précision du modèle (boosting)

Champs Options de génération Options de modèle Annotations

Sélectionner un élément :

- Objectifs
- Bases**
- Règles d'arrêt
- Ensembles
- Avancé

Modèle de réseau neuronal: Perceptron multicouche (MLP)

Couches masquées

☒ Calculer automatiquement le nombre d'unités

☐ Personnaliser le nombre d'unités

Couche masquée 1: 1


Couche masquée 2: 0


b. Combien de couches cachées et d'unités sont incluses dans le modèle ?

Il y a une couche cachée et 6 unités/neurones dans cette couche.

Récapitulatif du modèle

Cible	Work_From_Home
Modèle	Perceptron multicouche
Règles d'arrêt utilisées	L'erreur ne peut être plus réduite
Neurones de première couche masquée	6





c. Déterminez le taux de succès du modèle ainsi que sa sensibilité et sa précision

Le taux de succès est 80,38%, sa sensibilité est 100% et la précision est 80,38%.

Neurone

Fichier Edition

Analyse Annotations

Réduire tout Développer tout

Résultats du champ de sortie Work_From_Home

Comparaison de \$N-Work_From_Home avec Work_From_Home

'Partition'	1_Apprentissage		2_Test	
Correct	5 424	80,39 %	1 811	80,38 %
Incorrect	1 323	19,61 %	442	19,62 %
Total	6 747		2 253	

Matrice de coïncidences pour \$N-Work_From_Home (lignes affichant les valeurs réelles)

'Partition' = 1_Apprentissage		
0.000000		1 323
1.000000		5 424
'Partition' = 2_Test		
0.000000		442
1.000000		1 811

d. Utilisez le « boosting » pour améliorer les performances du modèle

Objectif : Précision du modèle (boosting)

Champs Options de génération Options de modèle Annotations

Sélectionner un élément :

- Objectifs
- Bases
- Règles d'arrêt
- Ensembles
- Avancé

Que voulez-vous faire ?

☐ Créer un modèle

☐ Poursuivre l'apprentissage du modèle existant

Quel est votre objectif principal ?

☐ Créer un modèle standard

☒ Améliorer la précision du modèle (boosting)

☐ Améliorer la stabilité du modèle (bagging)

☐ Optimiser les très grands jeux de données (requiert le serveur)

Description

Crée un ensemble en utilisant le boosting, qui génère une séquence de modèles pour obtenir des prévisions plus précises. La création et l'évaluation des ensembles peut prendre davantage de temps qu'un modèle standard. Cette option est ignorée pour les cibles multiples.

La matrice de confusion n'a pas changé montrant ainsi qu'il n'y a pas d'amélioration.

Neuronne

Fichier Edition

Analyse Annotations

- Réduire tout + Développer tout

Résultats du champ de sortie Work_From_Home

Comparaison de \$N-Work_From_Home avec Work_From_Home

'Partition'	1_Apprentissage		2_Test	
Correct	5 424	80,39 %	1 811	80,38 %
Incorrect	1 323	19,61 %	442	19,62 %
Total	6 747		2 253	

Matrice de coïncidences pour \$N-Work_From_Home (lignes affichant les valeurs réelles)

'Partition' = 1_Apprentissage	1.000000
0.000000	1 323
1.000000	5 424

'Partition' = 2_Test	1.000000
0.000000	442
1.000000	1 811

5. Utilisation des modèles KNN, les arbres de décision et les réseaux de neurones pour classer les enregistrements du jeu de données « COVID-impact-null ». Que peut-on conclure ?

Les quatre modèles ont classé l'ensemble des individus dans la classe 1 (**L'employé a commencé le travail à domicile en raison de la pandémie**). Ce résultat rejoint les résultats obtenus dans nos différentes matrix de confusion. Le modèle est incapable de prédire la classe 0 malgré le fait que les données soient équilibrées.

Partie II : Contexte

Dans cette partie du projet, nous considérons le jeu de données « Clients ». Il s'agit d'un ensemble de données avec des caractéristiques de 10 000 clients de votre entreprise qui a un système de carte de fidélité et qui propose des produits et des services en ligne à sa clientèle. Votre entreprise compte lancer une campagne de publicité ciblée. Elle envisage d'utiliser deux stratégies de publicité. La première stratégie est destinée aux clients ayant une « Valeur moyenne du panier d'achat » inférieure ou égale à 150 \$ et la deuxième stratégie cible les clients avec une « Valeur moyenne du panier d'achat » supérieure à 150 \$.

Votre gestionnaire vous demande de l'aider à identifier les clients ayant tendance à dépenser plus par transaction et à orienter les stratégies marketing en fonction de leur potentiel de dépense. Ainsi, pour bien cibler les publicités, votre gestionnaire veut classer les clients en deux catégories. Il vous fournit le jeu de données des 10 000 clients et un autre jeu avec des clients non classés. Il vous demande de trouver le meilleur moyen pour arriver à cette fin.

Travail demandé

Votre travail consiste à essayer les algorithmes KNN, les arbres de décision, les forêts aléatoires et les réseaux de neurones pour trouver la meilleure approche de classification. Vous devez aussi classer les clients du deuxième jeu (Clients_null) selon toutes les approches (KNN, arbres de décision, forêt aléatoire et réseaux de neurones), puis fournir une conclusion à votre gestionnaire. N'oubliez pas que l'exploration de données est un processus à plusieurs étapes.

1. Analyse descriptive du jeu de données Clients

Le jeu de données contient 10 000 observations/clients et 13 variables présentées dans le tableau 1 ci-après, assorties de la nature de chacune des variables. Concernant la nature de ces variables, 04 sont catégorielles et 09 numériques. Le jeu de données ne contient pas de valeurs manquantes.

Tableau 1 : Présentation des différentes variables du jeu de données

Variable	Description de la variable	Nature de la variable
Client_ID	Identifiant du client.	Numérique
Age	Âge du client.	Numérique
Genre	Genre du client (Femme/Homme).	Catégorielle
Revenu	Revenu annuel du client en milliers de dollars.	Numérique
Durée_adhésion	Ancienneté en mois.	Numérique
Dernier_achat	Temps écoulé depuis le dernier achat (en jours).	Numérique
Moy_valeur_panier	Valeur moyenne du panier d'achat .	Numérique
Catégorie_favorite	Catégorie préférée de produit ("Beauté", "Électronique", "Maison", "Mode", "Sport").	Catégorielle
Abonné_newsletter	Abonnement à la newsletter (Oui/Non).	Catégorielle
Segment	Segment du client ("VIP", "Fidèle", "Occasionnel", "Prospect").	Catégorielle
Visites_en_ligne_dernier_mois	Nombre de visites en ligne sur le site le mois dernier.	Numérique
Points_de_fidélité	Points de fidélité accumulés.	Numérique
Social_media_engagement	Niveau d'engagement sur les réseaux sociaux (de 0 à 5).	Numérique

Les statistiques descriptives sur les variables continues présentées dans le tableau 2 montrent que l'âge moyen des clients est 41,05 ans et le revenu annuel est 59 350 \$. La durée d'adhésion moyenne est de 25,61 mois et la valeur moyenne du panier est de 96,48\$. On a enregistré en moyenne 9 visites en ligne au cours du mois dernier. Le

nombre moyen de point de fidélité par client est de 1313 et le niveau d'engagement moyen des clients sur les réseaux sociaux est de 2,52.

Enfin, l'âge moyen du client est 55,59 ans. Le plus jeune client a 20 ans et le plus âgé 90 ans.

Tableau 2 : Statistiques descriptives sur les variables continues

Variables	Min	Mean	sd	Max
Age	18	41,05	13,48	64
Revenu	20	59,35	23,12	99
Durée_adhésion	1	25,61	17,49	59
Dernier_achat	1	151	96,83	364
Moy_valeur_panier	5,23	96,48	64,86	219,98
Visites_en_ligne_dernier_mois	0	9,401	5,78	19
Points_de_fidélité	10	1313	1377,9	4999
Social_media_engagement	0	2,517	1,70	5

La variable *Seuil_panier* a été créée à partir de la variable *Moy_valeur_panier*. Elle vaut 0 si la valeur moyenne du panier est inférieure ou égale à 150\$ et 1 dans le cas contraire. Elle permettra d'effectuer des analyses selon les objectifs de l'entreprise.

L'ensemble des variables catégorielles est présenté dans le tableau 3 ci-dessous. Les clients sont presque équitablement répartis par *catégorie favorite*, chaque catégorie comptant environ 20% des clients. Il y a presque autant d'hommes que de femmes. Le segment *Occasionnel* est le segment de la clientèle qui compte le plus de client, soit 34,35%. Enfin, 73,70% des clients ont un panier dont la valeur est inférieure ou égale à 150\$.


Tableau 3: Statistiques sur les variables catégorielles

Variables	Modalités	n	Prop
Catégorie_favorite	Beauté	2011	20,11
	Maison	1996	19,96
	Mode	2006	20,06
	Sport	2006	20,06
	Électronique	1981	19,81
	Total	10000	100,00
Abonné_newsletter	Non	4933	49,33
	Oui	5067	50,67
	Total	10000	100,00
Genre	Femme	4998	49,98

	Homme	5002	50,02
	Total	10000	100,00
Segment	Fidèle	3345	33,45
	Occasionnel	3435	34,35
	VIP	3220	32,20
	Total	10000	100,00
Seuil_panier	150 \$ ou moins	7370	73,70
	Plus 150 \$	2630	26,30
	Total	10000	100,00

Le pourcentage de clients avec un panier moyen inférieur à 150\$ est plus important dans la catégorie favorite Mode.


Figure 1: Diagramme en barres et en barres empilées de la variable seuil_panier en fonction de la variable catégorie favorite






La durée d'adhésion moyenne chez les clients ayant un panier moyen supérieur à 150\$ est supérieure à celle des clients ayant un panier moyen inférieur ou égal à 150\$. Le

même constat est fait avec la variable *points de fidélité*. Ces deux variables sont susceptibles de jouer un rôle plus important.

Figure 2 : Boxplots de la variable *Seuil_panier* en fonction d'autres variables d'intérêt





2. Modélisation

Dans l'ensemble des processus de modélisation, la base de données a été subdivisée en échantillon d'entraînement (75%) et test (25%). Les analyses ont été effectuées sous R. L'objectif de l'entreprise vis-à-vis d'un client est de faire en sorte que ce dernier dépense le plus. Nous considérons les Panier de 150\$ et plus comme les positifs dans nos prédictions.

a. Modélisation par KNN

Dans le cadre de la modélisation par KNN, la validation croisée a été utilisée pour déterminer le nombre de voisins k qui minimise l'erreur. Le k optimal est 18 pour une erreur de 26,56% (avec la fonction de kernel rectangulaire). En utilisant la fonction de kernel par défaut (distance de Minkowski) on a un k de 19 et une erreur de 27,59%.

```
##[r]
# échantillons test et entraînement en conservant les memes indices sur les arbres
clients.train_knn <- Dataset_KNN[train,]
clients.test_knn <- Dataset_KNN[-train,]

## validation croisée pour trouver le meilleur k
# définir la grille de recherche de k
k_values <- seq(1, 20, by = 2)

# Effectuer la validation croisée pour trouver le meilleur k
cv_kknn0 <- train.kknn(clients.train_knn$Seuil_panier ~ ., data = clients.train_knn, kmax = max(k_values), kernel = "rectangular", kcv = 10) ## par défaut c'est la distance de Minkowski

# Afficher les résultats de la validation croisée
print(cv_kknn0) # le meilleur k est ainsi 18
...

Call:
train.kknn(formula = clients.train_knn$Seuil_panier ~ ., data = clients.train_knn, kmax = max(k_values), kernel = "rectangular", kcv = 10)

Type of response variable: nominal
Minimal misclassification: 0.2656
Best kernel: rectangular
Best k: 18
```

Le modèle a été estimé avec k=18 et la matrice de confusion sur données test est ci-dessous présentée.

```
set.seed(1)
library(class)
# Appliquons le knn avec k=18 et évaluons la performance avec les données test
# On reconvertisse
clients.train_knn <- data.frame(lapply(clients.train_knn, function(x) if(is.factor(x)) as.numeric(x) else x))
clients.test_knn <- data.frame(lapply(clients.test_knn, function(x) if(is.factor(x)) as.numeric(x) else x))

knn.pred <- knn(clients.train_knn, clients.test_knn, clients.train_knn$Seuil_panier, k = 18)
summary(knn.pred)

# créer une matrice de confusion en spécifiant la classe positive
library(caret)
conf_matrix <- confusionMatrix(factor(knn.pred, levels = c(1, 2)),
                               factor(clients.test_knn$Seuil_panier, levels = c(1, 2)))

# Afficher la matrice de confusion modifiée
print(conf_matrix)
...

      1      2
2468    32
Confusion Matrix and Statistics

      Reference
Prediction  1      2
1 1791    677
2   23     9
```

Le taux de succès estimé est de 71,72%. La sensibilité est de 1,31% et la spécificité est de 98,73%. Pour rappel, le panier de 150\$ *et plus* correspond à positif. La précision est de 28,12%.

Nous avons finalement appliqué le modèle sur la base clients_null et avons obtenu le résultat suivant. Le modèle classe tous les 20 clients comme ayant un panier moyen inférieur ou égale à 150\$.

```
clients_null_e_knn<- data.frame(apply(clients_null_e_knn, function(x) if(is.factor(x)) as.numeric(x) else x))
knn.pred_null <- knn(clients.train_knn , clients_null_e_knn, clients.train_knn$Seuil_panier, k = 18)
summary(knn.pred_null)
```

	1	2
	20	0


b. Modélisation par arbres de décision

Dans le cadre de la modélisation par arbre de décision, nous avons utilisé la validation croisée pour le choix du nombre de nœuds terminaux. Dans un premier temps, nous avons retenons un arbre à 3 nœuds terminaux. Le taux d'erreur obtenu sur données d'apprentissage est de 25,89%.

```
##{r}
# validation croisée
cv.clients <- cv.tree(tree.clients, FUN = prune.misclass)
names(cv.clients)
cv.clients$dev # erreur validation croisée à minimiser
cv.clients$size # nombre de nœuds terminaux
```

	"size"	"dev"	"k"	"method"
[1]	1942	1942		
[1]	3	1		

La durée d'adhésion et le nombre de points de fidélité sont les principales variables qui permettent de prédire le seuil de revenus. Cependant, notre modèle ne prédit pas le seuil du panier *Plus de 150\$*. Ceci ne permettra d'orienter convenablement la stratégie marketing souhaitée.



Le modèle ne parvient pas à prédire la modalité *150 \$ et plus*.

```

{r}
# une verification personnelle sur train data
clients.train <- Dataset[train,]
seuil_panier.train <- Seuil_panier[train]

tree.pred <- predict(tree.clients, clients.train , type = "class")
table(tree.pred, Seuil_panier.train )

```

	Seuil_panier.train	
tree.pred	150 \$ ou moins	Plus 150 \$
150 \$ ou moins	5508	1992
Plus 150 \$	0	0

Pour améliorer notre modèle, nous avons procédé à un rééquilibrage des données. Nous avons successivement «augmentée» la part de la modalité *Plus de 150\$* de 0.2, 0,3, 0,4 et 0.5 avant d'observer un changement dans la capacité à prédire la modalité *Plus de 150\$*. L'effectif de cette classe est passé virtuellement de de 2630 à 4953.

```

# Arbre de Décision
{r}
# Balancer les données
Datasete <- Dataset2

# visualison d'abord Dataset2
table(Datasete$Seuil_panier)

# Installer et charger le package ROSE
#install.packages("ROSE")
#library(ROSE)

# Appliquer la fonction ROSE pour équilibrer les données
Datasete_balance <- ROSE(Seuil_panier ~ ., data = Datasete, seed = 1, p = 0.5)$data

# Vérifier la distribution des classes
table(Datasete_balance$Seuil_panier)

```


	150 \$ ou moins	Plus 150 \$
Before	7370	2630
After	5047	4953

Le taux d'erreur sur les données d'entraînement dans ce cas est de 41,97%.

```
# Pour résumer les résultats |
summary(tree.train)
# taux d'erreur de 26,51%
# "durée_adhésion" et "Points_de_fidélité" retenues

Classification tree:
tree(formula = Seuil_panier ~ ., data = data_train)
Variables actually used in tree construction:
[1] "durée_adhésion" "Points_de_fidélité"
Number of terminal nodes: 3
Residual mean deviance: 1.347 = 10100 / 7497
Misclassification error rate: 0.4197 = 3148 / 7500
```

Toutefois, le modèle est capable de prédire l'ensemble des modalités.



Donc, lorsque la durée d'adhésion est supérieure à 19,06 mois le panier moyen a une valeur de 150\$ et plus. Lorsque cette durée est inférieure à 17,06 mois et les points de fidélité inférieurs à 1302.05 le panier est inférieur ou égal à 150\$.

En appliquant, le modèle sur les données test, on a la matrice de confusion suivante, avec un taux de succès de 57,36%.

```
```{r}
tree.pred <- predict(tree.clients, clients.test, type = "class")
table(tree.pred, Seuil_panier.test)
```

      Seuil_panier.test
tree.pred  150 $ ou moins  Plus 150 $
150 $ ou moins      396      199
Plus 150 $          821     1084
```

| | seuil_panier.test | |
|-----------------|-------------------|-------------|
| tree.pred | 150 \$ ou moins | Plus 150 \$ |
| 150 \$ ou moins | 423 | 230 |
| Plus 150 \$ | 836 | 1011 |

Compte tenu du fait plus de 150\$ correspond au positif,

Sensibilité ou rappel ou encore le taux de vrais positifs (sensitivity or recall) :

$$Se = TVP = \text{rappel} = \frac{VP}{VP + FN}$$

$$Se = 1011 / (1011 + 230) = 1011 / 1241 \quad \text{Se} = 81,46\%$$

La précision (precision) :

$$\text{précision} = \frac{VP}{VP + FP}$$

$$\text{Précision} = 1011 / (1011 + 836) = 1011 / 1847$$

$$\text{Précision} = 54,73\%$$

Nous avons finalement appliqué le modèle sur la base clients_null. Nous avons le résultat suivant. 18 clients sont classés comme ayant un panier moyen supérieur à 150\$.

```

```{r}
base de données clients null
tree.pred_clients_null <- predict(prune.clients, clients_null_e,
 type = "class")

summary(tree.pred_clients_null)
```

```

| | |
|-----------------|-------------|
| 150 \$ ou moins | Plus 150 \$ |
| 2 | 18 |

```

[1] Plus 150 $    Plus 150 $    Plus 150 $    Plus 150 $    Plus 150 $    Plus 150 $
[7] Plus 150 $    Plus 150 $    150 $ ou moins Plus 150 $    Plus 150 $    Plus 150 $
[13] Plus 150 $    Plus 150 $    150 $ ou moins Plus 150 $    Plus 150 $    Plus 150 $
[19] Plus 150 $    Plus 150 $
Levels: 150 $ ou moins Plus 150 $

```

c. Modélisation par forêts aléatoires

Dans le cadre de la modélisation du Seuil_panier par forêts aléatoires, nous avons eu un taux d'erreur de 26,56% sur les données d'entraînement. Le modèle est capable de prédire toutes les modalités de l'attribut cible.

```
model_train_forest <- randomForest(Seuil_panier ~ . - 1,
  data = Dataset_forest2,
  subset = train,
  mtry = 6, # indique le nombre de prédicteurs à considérer
            # si ce nombre est égal au nombre total de prédicteurs
            # alors on est dans le bagging
            # Pour une random on prend mtry=p/3 par défaut
  importance = TRUE # voir importance de chaque variable
)

model_train_forest|
```

```
Call:
randomForest(formula = Seuil_panier ~ . - 1, data = Dataset_forest2,
  subset = train, mtry = 6, importance = TRUE,
  Type of random forest: classification
  Number of trees: 500
  No. of variables tried at each split: 6

  OOB estimate of error rate: 26.45%
Confusion matrix:
      150 $ ou moins  Plus 150 $ class.error
150 $ ou moins      5486       70 0.01259899
Plus 150 $          1914       30 0.98456790
```

Dans ce cas, la Durée d'adhésion et les points de fidélité demeurent les variables les plus importantes au regard de leur poids sur la variation de la précision. Elles sont suivies dans une certaine mesure de la variable *Dernier_achat*.

```
importance(model_train_forest)
```

| | 150 \$ ou moins | Plus 150 \$ | MeanDecreaseAccuracy | MeanDecreaseGini |
|-------------------------------|-----------------|-------------|----------------------|------------------|
| client_ID | 4.2456488 | 4.6329628 | 5.9460364 | 413.78243 |
| Age | -0.4534363 | 1.1102261 | 0.2117095 | 292.89984 |
| Genre | 1.7028713 | 2.1193768 | 2.6101271 | 37.52637 |
| Revenu | -1.2209400 | -3.5266131 | -2.9799857 | 318.87033 |
| Durée_adhésion | 44.5270769 | 11.3204542 | 43.8016661 | 335.88447 |
| Dernier_achat | 8.2829623 | 3.8565190 | 9.2228126 | 379.02038 |
| Catégorie_favorite | -0.1036572 | -0.9528742 | -0.6332824 | 166.43799 |
| Abonné_newsletter | -0.4312972 | -1.7128227 | -1.3290249 | 47.25323 |
| Segment | 0.4043026 | -0.9386699 | -0.1957316 | 80.89039 |
| Visites_en_ligne_dernier_mois | 2.4440172 | 3.7377276 | 4.0492570 | 243.45030 |
| Points_de_fidélité | 31.6648789 | 6.3118750 | 32.2576581 | 424.57182 |
| Social_media_engagement | -1.2675068 | -1.3503262 | -1.8153553 | 139.98084 |

En appliquant le modèle sur les données test, on a un taux de succès de 71,96%

```

set.seed(1)
# Application sur les données test
clients.test_forest <- Dataset_forest2[-train, ]

#Predict
pred_forest <- predict(model_train_forest, newdata = clients.test_forest)

#Matrix de confusion
conf_matrix_forest <- confusionMatrix(pred_forest,
                                       clients.test_forest$Seuil_panier
                                       )
# Afficher la matrice de confusion modifiée
print(conf_matrix_forest)

```

Confusion Matrix and Statistics

| | Reference | |
|-----------------|-----------------|-------------|
| Prediction | 150 \$ ou moins | Plus 150 \$ |
| 150 \$ ou moins | 1789 | 676 |
| Plus 150 \$ | 25 | 10 |

Accuracy : 0.7196

Nos positifs correspondent toujours à la modalité *Plus 150\$*.

Sensibilité ou rappel ou encore le taux de vrais positifs (sensitivity or recall) :

$$Se = TVP = \text{rappel} = \frac{VP}{VP + FN}$$

$$Se = 10 / (10+676) \quad \mathbf{Se = 1,45\%}$$

La précision (precision) :

$$\text{précision} = \frac{VP}{VP + FP}$$

$$\text{Précision} = 10/(10+25)$$

$$\mathbf{\text{Précision} = 28,57\%}$$

La spécificité est de **98,62%**

Nous avons appliqué le modèle sur la base clients_null et avons obtenu le résultat ci-après.

```

```{r}
Pour la prédiction sur la base clients_null
clients_null_e_forest <- clients_null_e

#Predict
pred_forest <- predict(model_train_forest, newdata = clients_null_e_forest)

#resultat
pred_forest|

ftable(pred_forest)
```

```

| pred_forest | 150 \$ ou moins | Plus 150 \$ |
|-------------|-----------------|-------------|
| | 10 | 10 |

| | | | | | |
|-----------------|-----------------|-----------------|-----------------|-----------------|-------------|
| 1 | 2 | 3 | 4 | 5 | 6 |
| 150 \$ ou moins | Plus 150 \$ | 150 \$ ou moins | Plus 150 \$ | Plus 150 \$ | Plus 150 \$ |
| 7 | 8 | 9 | 10 | 11 | 12 |
| 150 \$ ou moins | Plus 150 \$ | 150 \$ ou moins | Plus 150 \$ | Plus 150 \$ | Plus 150 \$ |
| 13 | 14 | 15 | 16 | 17 | 18 |
| 150 \$ ou moins | 150 \$ ou moins | 150 \$ ou moins | 150 \$ ou moins | 150 \$ ou moins | Plus 150 \$ |
| 19 | 20 | | | | |
| 150 \$ ou moins | Plus 150 \$ | | | | |

Levels: 150 \$ ou moins Plus 150 \$

Des 20 clients, 10 sont classés comme ayant un panier moyen supérieur à 150\$.

d. Modélisation par réseaux de neurones

Dans le cas de la modélisation par réseaux de neurones, nous avons eu un taux de réussite de 73,79% sur les données test, une sensibilité de $1/(1+654) = 0,15\%$ et une précision de $1/(1+0) = 100\%$.

Résultats du champ de sortie Seuil_panier


Comparaison de \$N-Seuil_panier avec Seuil_panier

| 'Partition' | 1_Apprentissage | | 2_Test | |
|-------------|-----------------|---------|--------|---------|
| Correct | 5 530 | 73,68 % | 1 841 | 73,79 % |
| Incorrect | 1 975 | 26,32 % | 654 | 26,21 % |
| Total | 7 505 | | 2 495 | |

Matrice de coïncidences pour \$N-Seuil_panier (lignes affichant les valeurs réelles)

| | | |
|-------------------------------|-----------------|-----------------|
| 'Partition' = 1_Apprentissage | | 150 \$ ou moins |
| 150 \$ ou moins | | 5 530 |
| Plus 150 \$ | | 1 975 |
| 'Partition' = 2_Test | 150 \$ ou moins | Plus 150 \$ |
| 150 \$ ou moins | 1 840 | 0 |
| Plus 150 \$ | 654 | 1 |

La durée d'adhésion et les points de fidélité sont les variables les plus importantes



Toutefois, face à cette incapacité du modèle de prédire convenablement suffisamment les cas de panier de plus de 150\$, nous avons tour à tour équilibré le jeu de données avec un facteur allant de 1 à 5. Le résultat était davantage moins acceptable parce que

seule la modalité *150\$ et moins* était prédictible. Nous avons aussi essayé d'améliorer le modèle avec du boosting et bagging sans obtenir de meilleurs résultats. Nous avons même procédé sans succès en faisant varier la taille de l'échantillon test entre 20% et 35% ou encore en modifiant le nombre de couches cachées.

Finalement, en appliquant le modèle sur le fichier clients_null, tous les 20 clients sont classés dans la catégorie *150\$ ou moins* correspondante aux clients dont la valeur moyenne du panier est inférieure ou égale à 150\$.

3. Evaluation des performances

Les performances des modèles ont déjà été évaluées dans chacun des cas précédents. Nous présentons ci-dessous, un tableau résumant les performances obtenues.

| Modèles | Précision | Sensibilité | Succès |
|---------------------|------------|--------------|--------------|
| KNN | 28,12 | 1,31 | 71,72 |
| Arbre de décision | 54,73 | 81,46 | 57,36 |
| Forêts aléatoires | 28,57 | 1,45 | 71,96 |
| Réseaux de neurones | 100 | 0,15 | 73,79 |

L'analyse des performances en termes de taux succès et de précision classe les réseaux de neurones au 1^{er} rang. Les arbres de décision occupent la première position en termes de sensibilité.

4. Déploiement (utilisation des modèles créés et bref rapport)

Nous avons également déployé le modèle dans chaque cas en utilisant sur les données clients_null. Les arbres de décision et les forêts aléatoires ont classés certains clients dans la catégorie de panier de 150\$ et plus. Les KNN et les réseaux de neurones ont classé tous les clients dans la catégorie de panier inférieur ou égale à 150\$.

L'objectif étant du mandat étant de cibler les clients ayant tendance à dépenser plus par transaction et à orienter les stratégies marketing en fonction de leur potentiel de dépense,

nous nous basons sur le **critère précision** pour choisir le modèle à proposer au gestionnaire. Dans ce cas, le réseau de neurones est le modèle recommandé. En plus, il a le taux de succès le plus élevé également.

Annexes

Modèle global KNN de la partie 1

